

***Matheurística* Híbrida aplicada ao Problema de p-Mediana Capacitado**

Gabriel Souto, Luidi Simonetti, Pedro Henrique González

Universidade Federal do Rio de Janeiro

R. Antônio Barros de Castro, 119 - Cidade Universitária, Rio de Janeiro - RJ, 21941-853

{soutog,luidi,pegonzalez}@cos.ufrj.br

RESUMO

O Problema das p-Mediana Capacitado (PPMC) é um problema NP-difícil aplicado em contextos de localização de facilidades, logística e planejamento de serviços, que busca selecionar instalações e alocar clientes minimizando custos de atendimento sob restrições de capacidade. Neste trabalho, propõe-se uma matheurística híbrida denominada *Hybrid Clustering Search Adaptive Iterated Local Search* (Hybrid-CS-AILS), que combina estratégias de construção GRASP, busca local baseada em *Variable Neighborhood Descent* (VND), um mecanismo adaptativo de *Iterated Local Search* (AILS) e um procedimento de intensificação que utiliza um modelo exato através de *Clustering Search*. Experimentos computacionais foram conduzidos em 35 instâncias benchmark clássicas do PPMC, comparando o método proposto com abordagens da literatura. Os resultados mostram que o Hybrid-CS-AILS obtém soluções competitivas em qualidade, em menor tempo computacional em relação aos métodos comparados, evidenciando a eficiência da estratégia híbrida proposta.

PALAVRAS CHAVE. Problema das p-Mediana Capacitado; Matheurísticas; Clustering Search; Iterated Local Search; Otimização Combinatória; Localização de Facilidades.

ABSTRACT

The Capacitated p-Median Problem (CPMP) is an NP-hard problem applied in facility location, logistics, and service planning contexts, which seeks to select facilities and allocate customers while minimizing service costs under capacity constraints. This work proposes a hybrid matheuristic called Hybrid Clustering Search Adaptive Iterated Local Search (Hybrid-CS-AILS), which combines GRASP construction strategies, local search based on Variable Neighborhood Descent (VND), an adaptive Iterated Local Search (AILS) mechanism, and an intensification procedure that uses an exact model through Clustering Search. Computational experiments were conducted on 35 classic benchmark instances of the CPMP, comparing the proposed method with approaches from the literature. The results show that Hybrid-CS-AILS achieves competitive solutions in terms of quality, with less computational time compared to the other methods, demonstrating the efficiency of the proposed hybrid strategy.

KEYWORDS. Capacitated p-Median Problem; Matheuristics; Clustering Search; Iterated Local Search; Combinatorial Optimization; Facility Location.

1. Introdução

Problemas de localização de facilidades desempenham um papel central em diversos sistemas reais, incluindo logística urbana, planejamento de serviços de saúde, distribuição de recursos e redes de transporte [Drezner, 1996; Revelle e Laporte, 1996; Owen e Daskin, 1998]. Nessas aplicações, decisões relacionadas à localização de instalações e à alocação de demanda impactam a eficiência operacional, os custos e a qualidade do serviço oferecido [Ullah et al., 2025].

Dentro desse contexto, o Problema das p -Medianas (PPM), originalmente introduzido por Hakimi [1964], destaca-se como um dos modelos fundamentais para problemas de localização e agrupamento. Este problema consiste, basicamente, em selecionar p instalações (medianas) dentre um conjunto de candidatos e alocar os clientes a essas instalações, minimizando a soma das distâncias entre os clientes e suas respectivas medianas. Uma extensão desta modelagem original e de grande relevância prática é o Problema das p -Medianas Capacitado (PPMC), no qual cada instalação possui uma capacidade limitada de atendimento [Mulvey e Beck, 1984; Pirkul, 1987].

Do ponto de vista computacional, o PPMC é um problema NP-difícil [Garey et al., 1990], o que inviabiliza o uso de métodos exatos para instâncias de grande escala em tempo computacional condizente com aplicações práticas. Dessa forma, a literatura deste problema tem explorado o uso de heurísticas, metaheurísticas e, mais recentemente, matheurísticas para obter soluções de alta qualidade em tempos computacionais reduzidos.

Diversas abordagens têm sido propostas para o PPMC, incluindo métodos exatos baseados em branch-and-bound, branch-and-cut e geração de colunas [Mulvey e Beck, 1984; Lorena e Senne, 2004; Boccia et al., 2008], bem como abordagens inspiradas em metaheurísticas clássicas como GRASP, algoritmos genéticos, busca tabu e Variable Neighborhood Search (VNS) [Osman e Christofides, 1994; Correa et al., 2004; Díaz e Fernandez, 2006; Fleszar e Hindi, 2008]. Mais recentemente, abordagens híbridas, conhecidas como matheurísticas, têm se destacado ao combinar estratégias de busca com modelos de programação matemática, permitindo explorar de forma mais eficiente regiões do espaço de soluções conforme feito por Stefanello et al. [2015].

Apesar dos avanços recentes em matheurísticas para o PPMC, ainda permanece um desafio importante: decidir quando e onde aplicar mecanismos exatos de intensificação sem comprometer a eficiência computacional do método. Neste contexto, este trabalho propõe uma matheurística híbrida denominada Hybrid-CS-AILS, cuja principal contribuição é um mecanismo de intensificação seletiva orientado pela densidade de ótimos locais observados durante a busca. A proposta integra um Adaptive Iterated Local Search (AILS) [Lourenço et al., 2003] com uma estratégia de Clustering Search Oliveira et al. [2013] capaz de identificar regiões promissoras do espaço de soluções. Deste modo, as principais contribuições deste trabalho são:

1. uma estratégia de intensificação guiada por densidade de ótimos locais obtidos durante a busca;
2. a integração entre Clustering Search e Adaptive Iterated Local Search como mecanismo de decisão para chamada de modelo de programação inteira mista;
3. um modelo baseado em subproblemas reduzidos adaptativamente definidos de acordo com o estado da busca;

A estrutura deste artigo está organizada da seguinte forma: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 descreve o Problema das p -Medianas Capacitado e sua formulação matemática; a Seção 4 detalha o método proposto e seus componentes; os experimentos computacionais e a análise dos resultados são apresentados na Seção 5; por fim, a Seção 6 apresenta as conclusões e direções para trabalhos futuros.

2. Trabalhos Relacionados

Desde sua proposição como extensão do problema clássico das p -medianas Hakimi [1964], o PPMC tem sido estudado tanto por métodos exatos quanto por abordagens heurísticas, motivado por aplicações em planejamento de saúde, logística urbana e alocação de recursos [Revelle e Laporte, 1996; Drezner, 1996]. Métodos exatos, incluindo enumeração implícita Mulvey e Beck [1984], *branch-and-cut* e geração de colunas Lorena e Senne [2004]; Ceselli e Righini [2005]; Boccia et al. [2008], garantem otimalidade, mas têm custo computacional proibitivo em instâncias de porte médio a grande, o que motivou o desenvolvimento de abordagens heurísticas e metaheurísticas como GRASP Resende e Werneck [2002], algoritmos genéticos Correa et al. [2004] e busca tabu Osman e Christofides [1994].

Entre as técnicas que servem de base ao método aqui proposto destaca-se o *Clustering Search* Chaves et al. [2008], que agrupa soluções de alta qualidade para guiar a intensificação a regiões promissoras do espaço de busca, e as abordagens híbridas que combinam metaheurísticas com modelos de programação inteira (matheurísticas).

Nessa linha, Stefanello et al. [2015] propõem o *Iterated Reduction Matheuristic Algorithm* (IRMA), baseado na redução do espaço de busca e resolução de subproblemas via programação inteira, e Vasconcelos et al. [2021] aplicam o *General Variable Neighborhood Search* (GVNS) ao PPMC, combinando múltiplas estruturas de vizinhança em um esquema sistemático. Mais recentemente, Freitas et al. [2025] descrevem uma metaheurística baseada em *Iterated Local Search* voltada especificamente ao PPMC, que constitui o comparativo direto deste trabalho por se tratar da contribuição mais recente da literatura e por operar no mesmo regime de tempo-qualidade visado pela abordagem proposta. A contribuição deste trabalho é a integração de *Clustering Search*, *Adaptive ILS* e intensificação via chamadas de programação inteira mista em um único framework, equilibrando diversificação e intensificação ao longo da busca.

3. Definição do Problema

O Problema das p -Medianas Capacitado (PPMC) consiste em selecionar exatamente (p) instalações e atribuir clientes a essas instalações minimizando o custo total de atendimento sob restrições de capacidade Pirkul [1987]; Mulvey e Beck [1984].

Considere um conjunto de instalações candidatas (N) e um conjunto de clientes (M) . Cada cliente $(j \in M)$ possui demanda $(q_j > 0)$, cada instalação $(i \in N)$ possui capacidade $(Q_i > 0)$, e (d_{ij}) representa o custo de atendimento entre (i) e (j) . O objetivo é selecionar exatamente $(p \leq n)$ medianas (instalações) e definir a alocação dos clientes.

Definem-se a variável binária y_i , que indica se a instalação i é selecionada como mediana ($y_i = 1$) ou não ($y_i = 0$), e a variável binária x_{ij} , que indica se o cliente j é atendido pela instalação i ($x_{ij} = 1$) ou não ($x_{ij} = 0$). A formulação matemática do PPMC é dada por:

$$\min \sum_{i \in N} \sum_{j \in M} d_{ij} x_{ij} \quad (1)$$

$$\sum_{i \in N} x_{ij} = 1 \quad \forall j \in M \quad (2)$$

$$\sum_{i \in N} y_i = p \quad (3)$$

$$\sum_{j \in M} q_j x_{ij} \leq Q_i y_i \quad \forall i \in N \quad (4)$$

$$x_{ij} \leq y_i \quad \forall i \in N, \forall j \in M \quad (5)$$

$$x_{ij} \in \{0, 1\} \quad \forall i \in N, \forall j \in M \quad (6)$$

$$y_i \in \{0, 1\} \quad \forall i \in N \quad (7)$$

A função objetivo (1) busca minimizar o custo total de atendimento, representado pela soma das distâncias entre clientes e suas respectivas instalações. As restrições (2) garantem que cada cliente seja atendido por exatamente uma instalação. A restrição (3) assegura que exatamente p instalações sejam selecionadas como medianas.

As restrições (4) impõem que a capacidade de cada instalação não seja excedida pela soma das demandas dos clientes a ela atribuídos. A restrição (5) garante a consistência entre as variáveis de decisão, permitindo que um cliente seja alocado a uma instalação apenas se esta estiver ativa como mediana. Por fim, as restrições (6) e (7) definem o domínio das variáveis de decisão.

4. Metodologia Proposta

Nesta seção, propomos uma abordagem híbrida para a resolução do Problema das p -Medianas Capacitado (PPMC), denominada *Hybrid Clustering Search Adaptive Iterated Local Search (Hybrid-CS-AILS)*. O método integra componentes heurísticos e exatos, combinando estratégias de construção, busca local, perturbação adaptativa e intensificação por meio do modelo de programação inteira.

Inicialmente, uma solução viável é gerada por meio de uma heurística construtiva do tipo *Greedy Randomized Adaptive Search Procedure (GRASP)*, descrita na Seção 4.1, que emprega uma lista restrita de candidatos e uma estratégia de alocação baseada em *regret* para garantir qualidade inicial e diversidade. Em seguida, a solução é refinada por uma fase de Busca Local baseada em *Variable Neighborhood Descent (VND)*, apresentada na Seção 4.2. Sobre essa base, o Hybrid-CS-AILS utiliza o *Adaptive Iterated Local Search (AILS)*, detalhado na Seção 4.3, no qual as soluções são iterativamente perturbadas e aprimoradas, equilibrando mecanismos de intensificação e diversificação ao longo do processo de busca.

Como mecanismo adicional de intensificação, incorporamos uma estratégia de *Clustering Search (CS)*, apresentada na Seção 4.4, que agrupa soluções visitadas ao longo da busca com base em um critério de similaridade. Essa informação é utilizada para identificar regiões promissoras do espaço de soluções, nas quais é aplicada uma etapa de refinamento mais intensivo. Desse modo, quando uma dada região se torna densa o suficiente, o CS aciona o *Partial Optimizer*, que resolve subproblemas reduzidos via programação inteira mista, conforme descrito na Seção 4.5. A Figura 1 ilustra o fluxo geral da abordagem Hybrid-CS-AILS, destacando a interação entre seus componentes principais.

4.1. Heurística Construtiva

A solução inicial foi inspirada nos trabalhos de Stefanello et al. [2015]; Resende e Werneck [2002]; Freitas et al. [2025] e atua combinando uma estratégia de alocação baseada em *regret*




Figura 1: Fluxo geral da abordagem Hybrid-CS-AILS

e um refinamento iterativo das medianas abertas. Dessa forma, sejam $d(i, j)$ a distância euclidiana entre os pontos i e j , q_j a demanda do cliente j e Q_i a capacidade da mediana candidata i . Para cada nó $i \in N$, calcula-se

$$g(i) = \sum_{j \in N} d(i, j), \quad (8)$$

que mede a centralidade de i em relação aos demais nós: valores menores de $g(i)$ correspondem a candidatos mais promissores para abrir uma mediana. A partir de $g(i)$, constrói-se a *Lista Restrita de Candidatos* (LRC) controlada pelo parâmetro $\alpha \in [0, 1]$:

$$\text{LRC} = \{ i \in N \mid g(i) \leq g_{\min} + \alpha (g_{\max} - g_{\min}) \}, \quad (9)$$

em que $g_{\min}$ e $g_{\max}$ são, respectivamente, o menor e o maior valor de g em N . O parâmetro α controla o grau de aleatoriedade: valores próximos de 0 aproximam o método de uma estratégia puramente gulosa, enquanto valores próximos de 1 aumentam a diversificação.

A cada tentativa de construção, p nós são sorteados uniformemente da LRC para compor o conjunto inicial de medianas abertas, denotado por V_m . A alocação dos clientes às medianas é realizada iterativamente por meio de um critério de *regret*, priorizando clientes cuja escolha da melhor mediana disponível é mais crítica. Para cada cliente j ainda não alocado, calcula-se

$$\text{regret}(j) = d(j, r_j^{(2)}) - d(j, r_j^{(1)}), \quad (10)$$

onde $r_j^{(1)}$ e $r_j^{(2)}$ são, respectivamente, a melhor e a segunda melhor mediana viável (em termos de distância e capacidade residual), escolhendo o cliente com maior $\text{regret}(j)$ em cada passo.

Visando uma representação mais compacta, seja $V_m \subseteq N$ o conjunto de medianas abertas, de modo que $y_i = 1 \iff i \in V_m$, e seja $v_a : M \rightarrow V_m$ a função de atribuição, tal que $x_{ij} = 1 \iff v_a(j) = i$. Dessa forma, após a alocação completa, cada mediana $r \in V_m$ é reavaliada dentro do seu próprio cluster $C_r = \{j \in N \mid v_a[j] = r\}$: seleciona-se como nova

mediana o nó $r' \in C_r$ que minimiza $\sum_{j \in C_r} d(j, r')$ desde que se mantenha viável. Em seguida, a alocação por *regret* é executada novamente sobre o novo conjunto de medianas, alternando com a etapa de reposicionamento até que o conjunto de medianas estabilize.

Se, em uma dada tentativa, algum cliente não encontra mediana viável durante o *regret*, a tentativa é descartada e uma nova amostragem de V_m é realizada, até um limite de `max_tries` tentativas.

4.2. Busca Local baseada em VND

A solução produzida pela fase construtiva é refinada por meio de uma busca local fundamentada no *Variable Neighborhood Descent* (VND) [Mladenović e Hansen, 1997; Freitas et al., 2025], que explora sistematicamente múltiplas estruturas de vizinhança até atingir um ótimo local em todas elas, adotando-se uma estratégia de *best-improvement*. As quatro vizinhanças implementadas são definidas a seguir.

M1 — Realocação de cliente. Move um cliente $j \in M$ de sua mediana atual $r_1 = v_a(j)$ para outra mediana aberta $r_2 \in V_m \setminus \{r_1\}$, isto é, altera apenas os valores de $x_{r_1 j}$ e $x_{r_2 j}$.

M2 — Substituição intra-cluster. Substitui uma mediana $r_1 \in V_m$ por um candidato $r_2 \in C_{r_1} \setminus V_m$, mantendo os clientes do cluster realocados a r_2 . Em termos das variáveis da formulação, alteram-se y_{r_1} de 1 para 0, y_{r_2} de 0 para 1.

M3 — Substituição inter-cluster. Substitui uma mediana $r_1 \in V_m$ por um candidato $r_2 \in N \setminus V_m$ pertencente a um cluster distinto, isto é, com $v_a(r_2) \neq r_1$. Após a substituição, o novo conjunto de medianas é $V'_m = (V_m \setminus \{r_1\}) \cup \{r_2\}$, e todos os clientes originalmente atribuídos a r_1 são realocados gulosamente às medianas remanescentes com capacidade residual suficiente.

M4 — Troca entre clientes. Permuta as atribuições de dois clientes $j_1, j_2 \in M$ alocados a medianas distintas, $r_1 = v_a(j_1)$ e $r_2 = v_a(j_2)$ com $r_1 \neq r_2$.

A ordem $M1 \rightarrow M2 \rightarrow M3 \rightarrow M4$ foi escolhida visando movimentos de menor custo computacional e maior efeito local (realocações e trocas simples), deixando as substituições estruturais de medianas, que alteram a estrutura da solução, como vizinhanças de maior impacto e maior custo.

4.3. Adaptive Iterated Local Search

O *Adaptive Iterated Local Search* (AILS) Lourenço et al. [2003] atua como framework do Hybrid-CS-AILS, partindo da construção GRASP e busca local VND (Seções 4.1 e 4.2). A cada iteração, o AILS aplica uma perturbação à solução corrente s , refaz a busca local VND sobre o resultado s' e decide se aceita s' como novo ponto de partida. A solução de melhor custo observada é mantida em s^* .

A adaptação em relação ao ILS clássico baseia-se em dois mecanismos. O primeiro é a intensidade variável da perturbação, controlada por um nível $\lambda \in \{1, \dots, 5\}$ que escala conforme a estagnação observada. O segundo é o acoplamento com o *Clustering Search* (Seção 4.4): a cada iteração, s' é observada pelo CS, que pode disparar uma etapa de intensificação exata via *Partial Optimizer* (Seção 4.5); quando essa etapa produz uma solução estritamente melhor que s , ela se torna a nova solução corrente.

A perturbação adaptativa combina dois tipos de movimento. O primeiro é uma substituição de medianas: sorteia-se $r_1 \in V_m$ para ser fechada e $r_2 \in N \setminus V_m$ para ser aberta; os clientes originalmente atribuídos a r_1 são realocados por um procedimento guloso baseado em *regret*, análogo ao da fase construtiva. O segundo é uma troca entre dois clientes de clusters distintos, sorteada

uniformemente. A composição da perturbação em função do nível λ segue o esquema: $\lambda=1$ aplica uma vez o primeiro mecanismo; $\lambda=2$, duas vezes o primeiro mecanismo; $\lambda=3$, duas vezes o primeiro mecanismo e uma vez o segundo; $\lambda=4$, três vezes o primeiro mecanismo; $\lambda=5$, três vezes o segundo mecanismo e uma vez o segundo.

O nível parte de $\lambda = 1$ e evolui segundo a seguinte regra: a cada iteração sem melhora, λ é incrementado até atingir $\lambda = 3$; avanços para $\lambda \in \{4, 5\}$ só ocorrem após a estagnação ultrapassar metade do orçamento de iterações ($\text{NumIterMax}/2$), sinalizando que as perturbações padrão não estão mais conduzindo a novas bacias de atração. Quando s' apresenta custo estritamente menor que s após o VND, o nível é reiniciado em $\lambda = 1$ e o contador de estagnação é zerado. A ideia discutida acima fica melhor formalizada no Algoritmo 1.

Algorithm 1 Adaptive Iterated Local Search (AILS)

Require: Solução inicial s (pós GRASP+VND); limites NumIterMax , $T_{\max}$

Ensure: Melhor solução encontrada s^*

```

1:  $s^* \leftarrow s$ ;  $\lambda \leftarrow 1$ ;  $k \leftarrow 0$ 
2: while  $k < \text{NumIterMax}$  e tempo  $< T_{\max}$  do
3:    $s' \leftarrow \text{Perturb}(s, \lambda)$ 
4:    $s' \leftarrow \text{VND}(s')$ 
5:    $\text{CS.OBSERVE}(s', s^*, s)$ 
6:   if  $s$  foi promovida pelo Partial Optimizer then
7:      $\lambda \leftarrow 1$ ;  $k \leftarrow 0$ ; atualizar  $s^*$  se melhor
8:   else if  $f(s') < f(s)$  then
9:      $s \leftarrow s'$ ;  $\lambda \leftarrow 1$ ;  $k \leftarrow 0$ ; atualizar  $s^*$ 
10:  else
11:     $k \leftarrow k + 1$ 
12:    atualizar  $\lambda$  conforme regra adaptativa
13:  end if
14: end while
15: return  $s^*$ 

```

▷ Algoritmo ??

▷ Seção 4.4

4.4. Clustering Search

O *Clustering Search (CS)* Oliveira et al. [2013] agrega os ótimos locais observados pelo AILS em um conjunto de γ grupos de similaridade (*clusters*). O objetivo é identificar regiões promissoras do espaço de soluções visitadas com frequência pela metaheurística, sobre as quais vale a pena investir uma etapa de intensificação mais custosa.

Pensando nisso, a cada iteração do AILS, a solução s' obtida após o VND é observada pelo CS. Calcula-se $\delta(s', c)$ para cada cluster ativo e seleciona-se o mais próximo c^* . Além disso, define-se a distância entre duas soluções a e b como

$$\delta(a, b) = p - |V_m^{(a)} \cap V_m^{(b)}|, \quad (11)$$

i.e., o número de medianas que não são compartilhadas. Cada cluster $c \in \{1, \dots, \gamma\}$ mantém um *centro* (a melhor solução já atribuída ao cluster), um *volume* (número de soluções associadas desde a última intensificação) e um contador de ineficácia.

Se existir espaço vago no dado cluster e $\delta(s', c^*) > \delta_{\text{thr}}$, cria-se um novo cluster com centro s' ; caso contrário, s' é atribuída a c^* , seu volume é incrementado e o centro é atualizado quando $f(s') < f(\text{centro})$. Adotamos $\delta_{\text{thr}} = \lceil p/4 \rceil$, de modo que soluções que divergem em até um quarto das medianas sejam classificadas como pertencentes a uma mesma região.

Quando o volume de um cluster atinge o limiar $v_{\max}$, dispara-se a intensificação sobre o centro daquele cluster (Seção 4.5). Após a intensificação, o volume é zerado: se houve melhoria, o centro é atualizado e o contador de ineficácia é reiniciado; caso contrário, o contador é incrementado, e o cluster aguarda nova acumulação de observações antes de ser reavaliado. Esse mecanismo evita que um cluster pouco promissor seja repetidamente alvo do *Partial Optimizer*.

4.5. Partial Optimizer

O *Partial Optimizer (PO)* é o componente exato do Hybrid-CS-AILS que é chamado sobre sub-regiões reduzidas da solução, formuladas como instâncias menores do PPMC resolvidas por um *solver* de programação inteira mista. A proposta é inspirada na matheurística adotada por Stefanello et al. [2015]: em vez de resolver o problema completo, o PO fixa a maior parte da solução corrente e permite que o *solver* resolva um subconjunto estruturalmente conectado de clusters.

Dado o centro $s = (V_m, v_a)$ do cluster do CS que disparou o gatilho, o PO começa escolhendo uma *mediana de referência* $r_{\text{ref}} \in V_m$: aquela cujo cluster $C_{r_{\text{ref}}}$ concentra o maior potencial de melhoria. Formalmente, associa-se a cada $r \in V_m$ o escore

$$\sigma(r) = 0,7 \cdot \underbrace{\sum_{j \in C_r} d_{rj}}_{\text{custo total}} + 0,3 \cdot \underbrace{\frac{1}{|C_r|} \sum_{j \in C_r} d_{rj}}_{\text{custo médio}}, \quad (12)$$

que combina o custo do cluster com o custo médio por cliente. A mediana de referência (r_{ref}) é sorteada aleatoriamente entre as três de maior σ , a fim de diversificar chamadas sucessivas do PO.

A partir de r_{ref} , constrói-se a *vizinhança espacial* $\mathcal{M}_{\text{livre}} \subseteq V_m$ das medianas que serão “liberadas” para reotimização: ordenam-se as medianas de V_m pela distância $d_{r_{\text{ref}}, r}$ em ordem crescente (de modo que $r_{\text{ref}} \in \mathcal{M}_{\text{livre}}$ é a primeira) e acumulam-se até cobrir pelo menos ω clientes ou atingir um limite $\kappa_{\max}$ de medianas. Os clientes atendidos por essas medianas compõem o conjunto $\mathcal{J} = \{j \in M \mid v_a(j) \in \mathcal{M}_{\text{livre}}\}$. As demais medianas $V_m \setminus \mathcal{M}_{\text{livre}}$ e seus respectivos clientes permanecem fixos: o subproblema MIP reotimiza apenas a alocação e a escolha de medianas dentro de $\mathcal{J}$, preservando o restante da solução. Duas outras reduções mantêm o subproblema tratável para as maiores instâncias. **R1**: para cada cliente $j \in \mathcal{J}$, o conjunto de medianas candidatas $\mathcal{K}_j$ é restrito aos vizinhos mais próximos admissíveis em capacidade. **R2**: para cada $r \in \mathcal{M}_{\text{livre}}$, apenas os β_{R2} nós mais próximos de r em seu cluster original podem abrir a mediana. Assim, o subproblema MIP reduzido é resolvido de modo exato por solvers comerciais.

5. Experimentos Computacionais

Esta seção avalia o desempenho do Hybrid-CS-AILS frente ao ILS de Freitas et al. [2025] (SBPO 2025), comparativo direto da abordagem proposta. Métodos como o IRMA Stefanello et al. [2015] e o GVNS Vasconcelos et al. [2021] operam em regime de tempo-qualidade distinto, privilegiando qualidade ao custo de tempos de execução de uma ordem de grandeza maior, e portanto não constituem comparativo direto. Na Seção 5.1 detalha-se a configuração da implementação, parâmetros adotados e instâncias utilizadas. Em seguida, são apresentadas as análises de qualidade (Seção 5.2) e de tempo computacional (Seção 5.3) das soluções obtidas.

5.1. Ambiente e Protocolo Experimental

Os experimentos foram executados em uma máquina com processador Intel Core i7-11800H (4,60 GHz) com 16 GB de RAM, sob sistema operacional Linux. O solver MILP utilizado no *Partial Optimizer* foi implementado no IBM CPLEX 22.11. O algoritmo foi implementado em C++17 e compilado com `-O3`.

O método foi avaliado sobre as 35 instâncias benchmark utilizadas em Stefanello et al. [2015], organizadas em 7 famílias, `lin318`, `ali535`, `u724`, `r11304`, `pr2392`, `fn14461` e

p3038, com 5 valores distintos de p cada. Cada instância foi executada $N = 10$ vezes com sementes aleatórias independentes. Os parâmetros α (GRASP), γ e $v_{\max}$ (*Clustering Search*) e β_{R2} (*Partial Optimizer*) foram calibrados automaticamente com o pacote *irace* López-Ibáñez et al. [2016], que aplica um procedimento de *racing* iterado sobre configurações candidatas, eliminando as estatisticamente inferiores em um conjunto de treinamento. A calibração empregou cinco instâncias de treino de famílias distintas, três *seeds* por instância e orçamento de 300 experimentos; a configuração elite obtida foi $\alpha = 0,6667$, $\gamma = 18$, $v_{\max} = 8$ e $\beta_{R2} = 16$.

Para cada instância, denotamos por Z_{ILS}^* o melhor custo reportado pelo ILS Freitas et al. [2025] entre suas execuções. A qualidade de uma solução Z obtida pelo Hybrid-CS-AILS é medida pelo *gap* percentual relativo a essa referência:

$$\text{gap}(Z) = \frac{Z - Z_{\text{ILS}}^*}{Z_{\text{ILS}}^*} \cdot 100 \%, \quad (13)$$

em que valores negativos indicam que o Hybrid-CS-AILS supera o ILS na métrica considerada.

5.2. Resultados Computacionais: Qualidade da Solução

Para cada instância, denotamos por Z_{best} o menor custo obtido entre as $N = 10$ execuções e por Z_{mean} o custo médio, e reportamos os *gaps* percentuais correspondentes em relação ao ILS (Equação 13).

A Tabela 1 consolida o desempenho do Hybrid-CS-AILS por família. O coeficiente de variação médio (CV%), que mede a dispersão relativa dos custos entre as 10 execuções, permanece abaixo de 0,45% em todas as sete famílias, indicando elevada estabilidade do método. Em termos de Z_{mean} , o Hybrid-CS-AILS supera o ILS em seis das sete famílias — com $\overline{\text{gap}}_{\text{mean}}$ negativo em todas elas exceto p3038 —, e o ganho global é de $-0,788\%$, com 22 vitórias contra 13 nas 35 instâncias avaliadas.

Tabela 1: Resultados agregados por família, com *gaps* percentuais calculados em relação ao ILS de Freitas et al. [2025] (Equação 13); valores negativos indicam que o Hybrid-CS-AILS supera o ILS. CV% é o coeficiente de variação médio dos custos entre as 10 execuções; *wins/losses* compara o Z_{mean} do Hybrid-CS-AILS com o custo médio reportado pelo ILS.

Família	#inst.	$\overline{\text{gap}}_{\text{best}}$ (%)	$\overline{\text{gap}}_{\text{mean}}$ (%)	CV (%)	wins/losses	Tempo (h)
lin318	5	-0,129	-0,210	0,215	3/2	3,15
ali535	5	-0,339	-2,788	0,344	5/0	4,03
u724	5	-0,405	-0,645	0,357	4/1	2,62
rl1304	5	+0,110	-0,278	0,404	2/3	6,73
pr2392	5	-0,087	-1,346	0,320	3/2	16,47
fn14461	5	+0,263	-0,630	0,422	4/1	32,11
p3038	5	+0,783	+0,383	0,376	1/4	49,30
Global	35	+0,028	-0,788	0,348	22/13	—

A vantagem observada em Z_{mean} é confirmada pelo teste pareado de Wilcoxon *signed-rank*, aplicado sobre a diferença dos custos médios com hipótese alternativa unilateral favorecendo o método proposto: rejeita-se a hipótese nula ao nível $\alpha = 0,05$ ($p = 0,011$, 22 vitórias contra 13 em 35 instâncias). A análise da distribuição dos *gaps* ao longo das 35 instâncias evidencia que, em Z_{best} , os dois métodos são equivalentes em qualidade (mediana próxima de zero), enquanto, em Z_{mean} , o Hybrid-CS-AILS apresenta variabilidade entre execuções substancialmente menor, traduzindo-se em soluções médias mais consistentes que as do ILS.

5.3. Resultados Computacionais: Eficiência Computacional

A contribuição central do Hybrid-CS-AILS se evidencia quando qualidade e tempo de execução são avaliados juntos. A Figura 2 apresenta, em escala logarítmica no eixo horizontal, o tempo médio versus o custo médio relativo (normalizado pelo melhor valor entre os dois métodos) para cada uma das 35 instâncias do Hybrid-CS-AILS e do ILS de Freitas et al. [2025]. O Hybrid-CS-AILS *Pareto*-domina o ILS em praticamente toda a extensão do gráfico: para cada ponto do ILS existe um ponto do Hybrid-CS-AILS com tempo menor e qualidade melhor.




Figura 2: Fronteira tempo $\times$ qualidade entre Hybrid-CS-AILS e ILS Freitas et al. [2025] sobre as 35 instâncias.

A magnitude do ganho temporal é quantificada pela média geométrica das razões $T_{\text{ILS}}/T_{\text{Hybrid}}$ por instância, agregada na Tabela 2. Globalmente, o Hybrid-CS-AILS é $6,7\times$ mais rápido que o ILS, com ganhos particularmente expressivos em ali535 ($19,0\times$) e u724 ($15,4\times$). A única família em que o ganho é modesto é p3038, em que a razão $p/n \geq 0,3$ leva o *Partial Optimizer* a um regime degradado.

Tabela 2: Tempo médio por família e *speedup* (média geométrica) do Hybrid-CS-AILS em relação ao ILS de Freitas et al. [2025].

Família	#inst.	T_{Hybrid} (s)	T_{ILS} (s)	<i>speedup</i>
lin318	5	227	615	$5,9\times$
ali535	5	290	2403	$19,0\times$
u724	5	189	1519	$15,4\times$
rl1304	5	485	4409	$11,7\times$
pr2392	5	1186	4147	$4,5\times$
fnl4461	5	2312	9139	$4,7\times$
p3038	5	3550	5042	$1,4\times$
Global	35	1177	3897	$6,7\times$

A combinação dos dois resultados — qualidade média superior e tempo de execução de uma ordem de grandeza menor — caracteriza uma região da fronteira tempo $\times$ qualidade ainda não explorada pelas abordagens previamente reportadas para o PPMC.

6. Conclusão

Neste trabalho foi proposta uma matheurística híbrida denominada *Hybrid-CS-AILS* para o Problema das p-Medianas Capacitado (PPMC). A abordagem integra mecanismos heurísticos e

exatos por meio da combinação entre uma heurística construtiva baseada em GRASP, busca local VND, um framework adaptativo de *Iterated Local Search* e um mecanismo de intensificação seletiva guiado por *Clustering Search*. Diferentemente de abordagens híbridas tradicionais, o método proposto utiliza o *Clustering Search* para auxiliar na decisão de quando aplicar o modelo do PPMC via programação inteira mista, concentrando esforço computacional em regiões promissoras do espaço de busca.

Os experimentos computacionais realizados em 35 instâncias benchmark clássicas do PPMC mostraram que o Hybrid-CS-AILS supera o ILS de Freitas et al. [2025], comparativo direto e referência mais recente da literatura, em termos de custo médio com significância estatística ($p = 0,011$ no teste pareado de Wilcoxon) e produz soluções, em média, 6,7 vezes mais rapidamente. Os resultados evidenciaram, ainda, elevada estabilidade entre execuções independentes em todas as sete famílias avaliadas.

Como perspectivas futuras, pretende-se investigar estratégias de aprendizado para seleção de regiões promissoras do espaço de busca como também avaliar a aplicação da abordagem proposta em outras variantes de problemas de localização de facilidades.

Referências

- Boccia, M., Sforza, A., Sterle, C., e Vasilyev, I. (2008). A cut and branch approach for the capacitated p-median problem based on fenchel cutting planes. *Journal of mathematical modelling and algorithms*, 7(1):43–58.
- Ceselli, A. e Righini, G. (2005). A branch-and-price algorithm for the capacitated p-median problem. *Networks: An International Journal*, 45(3):125–142.
- Chaves, A. A., de Assis Correa, F., e Lorena, L. A. N. (2008). Clustering search heuristic for the capacitated p-median problem. In *Innovations in Hybrid Intelligent Systems*, p. 136–143. Springer.
- Correa, E. S., Steiner, M. T. A., Freitas, A. A., e Carnieri, C. (2004). A genetic algorithm for solving a capacitated p-median problem. *Numerical Algorithms*, 35(2):373–388.
- Díaz, J. A. e Fernandez, E. (2006). Hybrid scatter search and path relinking for the capacitated p-median problem. *European Journal of Operational Research*, 169(2):570–585.
- Drezner, E. (1996). Facility location: A survey of applications and methods. *Journal of the Operational Research Society*, 47(11):1421–1421.
- Fleszar, K. e Hindi, K. S. (2008). An effective vns for the capacitated p-median problem. *European Journal of Operational Research*, 191(3):612–622.
- Freitas, B. A., de Souza, S. R., e de Sá, E. M. (2025). Metaheurística ils aplicada ao problema de p-mediana capacitado. In *Book of Abstracts of the LVIII Brazilian Symposium on Operations Research (SBPO 2025)*, Gramado, Brazil. Galoá. URL <https://proceedings.science/sbpo/sbpo-2025/trabalhos/metaheuristica-ils-aplicada-ao-problema-de-p-mediana-capacitado?lang=pt-br>. Accessed: 21 Apr. 2026.
- Garey, M. R., Johnson, D. S., et al. (1990). A guide to the theory of np-completeness. *Computers and intractability*, p. 37–79.

- Hakimi, S. L. (1964). Optimum locations of switching centers and the absolute centers and medians of a graph. *Operations research*, 12(3):450–459.
- López-Ibáñez, M., Dubois-Lacoste, J., Pérez Cáceres, L., Birattari, M., e Stützle, T. (2016). The irace package: Iterated racing for automatic algorithm configuration. *Operations Research Perspectives*, 3:43–58.
- Lorena, L. A. e Senne, E. L. (2004). A column generation approach to capacitated p-median problems. *Computers & Operations Research*, 31(6):863–876.
- Lourenço, H. R., Martin, O. C., e Stützle, T. (2003). Iterated local search. In *Handbook of metaheuristics*, p. 320–353. Springer.
- Mladenović, N. e Hansen, P. (1997). Variable neighborhood search. *Computers & Operations Research*, 24(11):1097–1100.
- Mulvey, J. M. e Beck, M. P. (1984). Solving capacitated clustering problems. *European Journal of Operational Research*, 18(3):339–348.
- Oliveira, A. C. M. d., Chaves, A. A., e Lorena, L. A. N. (2013). Clustering search. *Pesquisa operacional*, 33(1):105–121.
- Osman, I. H. e Christofides, N. (1994). Capacitated clustering problems by hybrid simulated annealing and tabu search. *International Transactions in Operational Research*, 1(3):317–336.
- Owen, S. H. e Daskin, M. S. (1998). Strategic facility location: A review. *European journal of operational research*, 111(3):423–447.
- Pirkul, H. (1987). Efficient algorithms for the capacitated concentrator location problem. *Computers & Operations Research*, 14(3):197–208.
- Resende, M. G. e Werneck, R. F. (2002). A grasp with path-relinking for the p-median problem. *Journal of Heuristics*.
- Revelle, C. S. e Laporte, G. (1996). The plant location problem: new models and research prospects. *Operations Research*, 44(6):864–874.
- Stefanello, F., de Araújo, O. C., e Müller, F. M. (2015). Matheuristics for the capacitated p-median problem. *International Transactions in Operational Research*, 22(1):149–167.
- Ullah, I., Noor, A., Abbas, M., Garg, S., Choi, B. J., Hassan, M. M., e Bai, X. (2025). Optimizing smart city services by utilizing appropriate characteristics of digital twin for urban excellence. *Alexandria Engineering Journal*, 122:399–410.
- Vasconcelos, A., Souza, M., e Souza, S. D. (2021). Algoritmo gvns híbrido aplicado ao problema das p-medianas capacitado. *Trends in Computational and Applied Mathematics*, 22(3):453–473.